

# ДИПЛОМ

Колтаков Михаил

Научный руководитель: Дахова Елизавета

24 апреля 2024 г.

Введём модель:

$$\begin{array}{ccc} X_{01}^1 & \dots & X_{01}^\tau \\ \dots & \dots & \dots \\ X_{0n}^1 & \dots & X_{0n}^\tau \end{array}$$

Где вдоль вертикальной оси меняются элементы батча, а вдоль горизонтальной — кадры. При этом для одного элемента батча можно ввести следующие латентные величины:

$$\begin{array}{ccccccc} X_0^1 & \rightarrow & X_1^1 & \rightarrow & \dots & \rightarrow & X_T^1 \\ \downarrow & & \downarrow & & & & \downarrow \\ X_0^2 & \rightarrow & X_1^2 & \rightarrow & \dots & \rightarrow & X_T^2 \\ \downarrow & & \downarrow & & \ddots & & \downarrow \\ \vdots & & \vdots & & \ddots & & \vdots \\ \downarrow & & \downarrow & & & \ddots & \downarrow \\ X_0^\tau & \rightarrow & X_1^\tau & \rightarrow & \dots & \rightarrow & X_T^\tau \end{array}$$

Объединим столбики в одну величину и дальше величины, обозначающие полное видео будем обозначать с волной:  $\tilde{X}$ . Тогда у нас получается марковская цепь  $\tilde{X}_0 \rightarrow \tilde{X}_1 \rightarrow \dots \rightarrow \tilde{X}_T$ , для которой можно ввести следующее вариационное семейство:

$$q\left(\tilde{X}_1, \dots, \tilde{X}_T \mid \tilde{X}_0\right) = \prod_{t=1}^T q_t\left(\tilde{X}_t \mid \tilde{X}_{t-1}\right)$$

В данной работе будем считать плотность между двумя соседними шагами зашумления следующей:

$$\tilde{X}_t \mid \tilde{X}_{t-1} \stackrel{\mathcal{Q}}{\sim} \mathcal{N}\left(\sqrt{1-\beta_t}\tilde{X}_{t-1}; \beta_t C\right), \text{ где } C = \begin{pmatrix} a & b & c & \dots \\ b & a & b & \dots \\ c & b & a & \dots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix} \text{ и полож. полуопред.}$$

Из этого по индукции получается следующее:

**Обозн.**  $\tilde{\alpha}_t = \prod_{s=1}^t \alpha_s, \quad \alpha_s = 1 - \beta_s$

**База.**  $\tilde{X}_1 \mid \tilde{X}_0 \stackrel{\mathcal{Q}}{\sim} \mathcal{N}\left(\sqrt{1-\beta_1}\tilde{X}_0; \beta_1 C\right) = \mathcal{N}\left(\sqrt{\tilde{\alpha}_1}\tilde{X}_0; (1-\tilde{\alpha}_1)C\right)$  по утверждению выше.

**Шаг.**  $\tilde{X}_t \mid \tilde{X}_{t-1} \stackrel{\mathcal{Q}}{\sim} \mathcal{N}\left(\sqrt{1-\beta_t}\tilde{X}_{t-1}; \beta_t C\right) = \sqrt{1-\beta_t}\tilde{X}_{t-1} + \sqrt{\beta_t}\varepsilon_t =$   
 $= \sqrt{1-\beta_t}\sqrt{\tilde{\alpha}_{t-1}}\tilde{X}_0 + \sqrt{1-\beta_t}\sqrt{1-\tilde{\alpha}_{t-1}}\varepsilon'_{t-1} + \sqrt{\beta_t}\varepsilon_t = \sqrt{\tilde{\alpha}_t}\tilde{X}_0 + \sqrt{1-\tilde{\alpha}_{t-1}}(1-\beta_t)\varepsilon'_t =$   
 $= \mathcal{N}\left(\sqrt{\tilde{\alpha}_t}\tilde{X}_0; (1-\tilde{\alpha}_t)C\right)$ . Предпоследний переход выполнен используя свойства сложения дисперсий суммы нормальных распределений. Все  $\varepsilon$  и  $\varepsilon'$  имеют распределение  $\mathcal{N}(\vec{0}; C)$ .

В итоге индукция доказывает верность для любого  $t$  следующего выражения:

$$\tilde{X}_t | \tilde{X}_0 \sim \mathcal{N} \left( \sqrt{\tilde{\alpha}_t} \tilde{X}_0; (1 - \tilde{\alpha}_t) C \right) \quad (1)$$

А значит, можно провести такую репараметризацию, выделив среднее как постоянную компоненту и оставить случайность в отдельном слагаемом с нулевым средним:

$$\tilde{X}_t \stackrel{dQ}{=} \sqrt{\tilde{\alpha}_t} \tilde{X}_0 + \sqrt{1 - \tilde{\alpha}_t} \delta_t \Rightarrow \tilde{X}_0 \stackrel{dQ}{=} \frac{1}{\sqrt{\tilde{\alpha}_t}} \left( \tilde{X}_t - \sqrt{1 - \tilde{\alpha}_t} \delta_t \right) \quad \delta_t \sim \mathcal{N} \left( \vec{0}; C \right)$$

Для обучения модели нужно уметь восстанавливать предыдущий этап зашумления, поэтому докажем следующее утверждение:

$$\tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \sim \mathcal{N} \left( \tilde{\mu}_t \left( \tilde{X}_t, \tilde{X}_0 \right), \tilde{\beta} C \right) \quad (2)$$

где  $\tilde{\mu} \left( \tilde{X}_t, \tilde{X}_0 \right) = \frac{\sqrt{\tilde{\alpha}_{t-1} \beta_t}}{1 - \tilde{\alpha}_t} \tilde{X}_0 + \frac{\sqrt{\tilde{\alpha}_t (1 - \tilde{\alpha}_{t-1})}}{1 - \tilde{\alpha}_t} \tilde{X}_t$ , а  $\tilde{\beta}_t = \frac{1 - \tilde{\alpha}_{t-1}}{1 - \tilde{\alpha}_t} \beta_t$ .

*Доказательство:* В течение этого доказательства будем обозначать  $Q(x) = x^T C^{-1} x$ . По теореме Байеса получаем  $q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right) = \frac{q(\tilde{X}_t | \tilde{X}_{t-1}, \tilde{X}_0) \cdot q(\tilde{X}_{t-1} | \tilde{X}_0)}{q(\tilde{X}_t | \tilde{X}_0)}$ , однако, в силу марковости процесса, в первой плотности можно убрать условность по  $\tilde{X}_0$ , тогда получим  $q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right) = \frac{q(\tilde{X}_t | \tilde{X}_{t-1}) \cdot q(\tilde{X}_{t-1} | \tilde{X}_0)}{q(\tilde{X}_t | \tilde{X}_0)}$ . Далее начнём работать с этим выражением. В первых распишем плотности, а потом уберём константу по пропорциональности, потому что мы знаем, что у нас получается корректное распределение

$$\begin{aligned} \frac{q \left( \tilde{X}_t | \tilde{X}_{t-1} \right) \cdot q \left( \tilde{X}_{t-1} | \tilde{X}_0 \right)}{q \left( \tilde{X}_t | \tilde{X}_0 \right)} &\propto \exp \left( -\frac{1}{2} \left( \frac{1}{\beta_t} Q \left( \tilde{X}_t - \sqrt{\alpha_t} \tilde{X}_{t-1} \right) + \right. \right. \\ &\left. \left. + \frac{1}{1 - \tilde{\alpha}_{t-1}} Q \left( \tilde{X}_{t-1} - \sqrt{\tilde{\alpha}_{t-1}} \tilde{X}_0 \right) - \frac{1}{1 - \tilde{\alpha}_t} Q \left( \tilde{X}_t - \sqrt{\tilde{\alpha}_t} \tilde{X}_0 \right) \right) \right) \end{aligned}$$

Как мы видим, в последнем слагаемом показателя  $\tilde{X}_{t-1}$  не участвует, поэтому можно про него тоже пока забыть. Продолжим преобразовывать показатель:

$$\begin{aligned} &\frac{1}{\beta_t} Q \left( \tilde{X}_t - \sqrt{\alpha_t} \tilde{X}_{t-1} \right) + \frac{1}{1 - \tilde{\alpha}_{t-1}} Q \left( \tilde{X}_{t-1} - \sqrt{\tilde{\alpha}_{t-1}} \tilde{X}_0 \right) = \\ &= \frac{\alpha_t}{\beta_t} \tilde{X}_{t-1}^T C^{-1} \tilde{X}_{t-1} - 2 \frac{\sqrt{\alpha_t}}{\beta_t} \tilde{X}_{t-1}^T C^{-1} \tilde{X}_t + \frac{1}{\beta_t} \tilde{X}_t^T C^{-1} \tilde{X}_t + \\ &+ \frac{1}{1 - \tilde{\alpha}_{t-1}} \tilde{X}_{t-1}^T C^{-1} \tilde{X}_{t-1} - 2 \frac{\sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_{t-1}} \tilde{X}_{t-1}^T C^{-1} \tilde{X}_0 + \frac{\tilde{\alpha}_{t-1}}{1 - \tilde{\alpha}_{t-1}} \tilde{X}_0^T C^{-1} \tilde{X}_0 \propto_{\ln} \\ &\propto_{\ln} \frac{\alpha_t (1 - \tilde{\alpha}_{t-1}) + \beta_t}{\beta_t (1 - \tilde{\alpha}_{t-1})} \tilde{X}_{t-1}^T C^{-1} \tilde{X}_{t-1} - 2 \tilde{X}_{t-1}^T C^{-1} \left( \frac{\sqrt{\alpha_t}}{\beta_t} \tilde{X}_t + \frac{\sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_{t-1}} \tilde{X}_0 \right) = \\ &= \frac{1 - \tilde{\alpha}_t}{\beta_t (1 - \tilde{\alpha}_{t-1})} \left( \tilde{X}_{t-1}^T C^{-1} \tilde{X}_{t-1} - 2 \tilde{X}_{t-1}^T C^{-1} \left( \frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} \tilde{X}_0 + \frac{\sqrt{\alpha_t} (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} \tilde{X}_t \right) \right) \end{aligned}$$

По этому показателю экспоненты мы видим, что  $\tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \sim \mathcal{N}$ , и что матрица ковариаций данного нормального распределения равна  $\frac{\beta_t (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} C$ , а

среднее равно  $\frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} \tilde{X}_0 + \frac{\sqrt{\alpha_t} (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} \tilde{X}_t$ . Что и требовалось доказать.

Если предсказывать моделью исходное изображение, то можно ввести аналогичную **утв. 2** функцию  $\mu_\theta(x_t, t) := \frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} x_\theta(x_t, t) + \frac{\sqrt{\alpha_t} (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} x_t$ , где  $x_\theta(x_t, t)$  — это предсказания модели.

Теперь выведем ELBo(будем обозначать как  $\mathcal{L}$ ) для модели, с которой мы будем работать:

$$\mathcal{L} = \mathbb{E}_q \log \frac{p_\theta \left( \tilde{X}_0, \dots, \tilde{X}_T \right)}{q \left( \tilde{X}_1, \dots, \tilde{X}_T | \tilde{X}_0 \right)} = \mathbb{E}_q \log p \left( \tilde{X}_T \right) + \sum_{t=1}^T \mathbb{E}_q \log \frac{p_\theta \left( \tilde{X}_{t-1} | \tilde{X}_t \right)}{q \left( \tilde{X}_t | \tilde{X}_{t-1} \right)} =$$

В последней сумме можно опустить условность по  $\tilde{X}_0$  в знаменателе в следствие марковости процесса. Далее применим уже использованную теорему Байеса:

$$q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right) = \frac{q \left( \tilde{X}_t | \tilde{X}_{t-1} \right) \cdot q \left( \tilde{X}_{t-1} | \tilde{X}_0 \right)}{q \left( \tilde{X}_t | \tilde{X}_0 \right)}:$$

$$\begin{aligned} &= \mathbb{E}_q \log p \left( \tilde{X}_T \right) + \mathbb{E}_q \log \frac{p_\theta \left( \tilde{X}_0 | \tilde{X}_1 \right)}{q \left( \tilde{X}_1 | \tilde{X}_0 \right)} + \sum_{t=2}^T \mathbb{E}_q \log \left( \frac{p_\theta \left( \tilde{X}_{t-1} | \tilde{X}_t \right)}{q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right)} \cdot \frac{q \left( \tilde{X}_{t-1} | \tilde{X}_0 \right)}{q \left( \tilde{X}_t | \tilde{X}_0 \right)} \right) = \\ &= \mathbb{E}_q \log p_\theta \left( \tilde{X}_0 | \tilde{X}_1 \right) + \mathbb{E}_q \log \frac{p_\theta \left( \tilde{X}_T \right)}{q \left( \tilde{X}_T | \tilde{X}_0 \right)} + \sum_{t=2}^T \mathbb{E}_q \log \frac{p_\theta \left( \tilde{X}_{t-1} | \tilde{X}_t \right)}{q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right)} = \\ &= \underbrace{\mathbb{E}_q \log p_\theta \left( \tilde{X}_0 | \tilde{X}_1 \right)}_{\approx \text{const}} - \underbrace{\text{KL} \left( q \left( \tilde{X}_T | \tilde{X}_0 \right), p_\theta \left( \tilde{X}_T \right) \right)}_{p_\theta \left( \tilde{X}_T \right) : \mathcal{N}(0, C) \quad q \left( \tilde{X}_T | \tilde{X}_0 \right) : \mathcal{N}(\sqrt{\tilde{\alpha}_T} \tilde{X}_0, (1 - \tilde{\alpha}_T) C)} - \\ &\quad - \sum_{t=2}^T \mathbb{E}_q \text{KL} \left( \underbrace{q \left( \tilde{X}_{t-1} | \tilde{X}_t, \tilde{X}_0 \right)}_{\mathcal{N}}, \underbrace{p_\theta \left( \tilde{X}_{t-1} | \tilde{X}_t \right)}_{\mathcal{N}} \right) \end{aligned}$$

Как мы видим, первое слагаемое — это константа, второе слагаемое — это почти 0, потому что при большом  $T$  распределения очень похожи. Теперь распишем  $KL$ -дивергенцию для этих двух нормальных распределений:

$$\begin{aligned} \text{KL} &= \frac{1}{2} \left( \underbrace{\text{tr} \left( C^{-1} C \right) - k + \ln \left( \frac{\det C}{\det \tilde{C}} \right)}_{=0} + \frac{1}{\tilde{\beta}_t} Q \left( \mu_\theta \left( \tilde{X}_t, t \right) - \tilde{\mu} \left( \tilde{X}_t, \tilde{X}_0 \right) \right) \right) = \\ &= \frac{1}{2\tilde{\beta}_t} \left( \mu_\theta \left( \tilde{X}_t, t \right) - \tilde{\mu} \left( \tilde{X}_t, \tilde{X}_0 \right) \right)^T C^{-1} \left( \mu_\theta \left( \tilde{X}_t, t \right) - \tilde{\mu} \left( \tilde{X}_t, \tilde{X}_0 \right) \right) = \\ &= \left/ \mu_\theta \left( \tilde{X}_t, t \right) - \tilde{\mu} \left( \tilde{X}_t, \tilde{X}_0 \right) = \frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} x_\theta + \frac{\sqrt{\tilde{\alpha}_t} (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} \tilde{X}_t - \frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} \tilde{X}_0 - \frac{\sqrt{\tilde{\alpha}_t} (1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} \tilde{X}_t = \right. \\ &= \frac{\beta_t \sqrt{\tilde{\alpha}_{t-1}}}{1 - \tilde{\alpha}_t} \left( x_\theta - \tilde{X}_0 \right) \left/ = \frac{\tilde{\alpha}_{t-1} \beta_t^2}{2\tilde{\beta}_t (1 - \tilde{\alpha}_t)^2} \left( x_\theta - \tilde{X}_0 \right)^T C^{-1} \left( x_\theta - \tilde{X}_0 \right) = \right. \\ &= \frac{\tilde{\alpha}_{t-1} \beta_t^2}{2\tilde{\beta}_t (1 - \tilde{\alpha}_t)^2} \cdot \frac{1 - \tilde{\alpha}_t}{\tilde{\alpha}_t} (\delta_t - \delta_\theta)^T C^{-1} (\delta_t - \delta_\theta) = \left/ \tilde{\beta}_t = \frac{1 - \tilde{\alpha}_{t-1}}{1 - \tilde{\alpha}_t} \beta_t \right/ = \\ &= \frac{\beta_t}{2\alpha_t (1 - \tilde{\alpha}_{t-1})} (\delta_t - \delta_\theta)^T C^{-1} (\delta_t - \delta_\theta) \end{aligned}$$

Значит, итоговое ELBo получаем

$$\mathcal{L} = \text{const} - \sum_{t=2}^T \frac{\beta_t}{2\alpha_t (1 - \tilde{\alpha}_{t-1})} \mathbb{E}_q (\delta_t - \delta_\theta)^T C^{-1} (\delta_t - \delta_\theta) \quad (3)$$

Значит, для обучения нельзя будет использовать простой MSE-loss, нужно будет модифицировать его, учитывая корреляции по времени.

## Непрерывный случай

Теперь перейдём к непрерывному случаю. В нём уравнение можно записать и преобразовать следующим образом:

$$\tilde{X}_{t+dt} = \sqrt{1 - \beta_t} \tilde{X}_t + \sqrt{\beta_t} \varepsilon_t \quad \varepsilon_t \sim \mathcal{N}(\vec{0}; C)$$

$$\tilde{X}_{t+dt} = \left(1 - \frac{1}{2}\beta_t dt + \bar{o}(dt)\right) \tilde{X}_t + \sqrt{\beta_t dt} \varepsilon_t$$

$$d\tilde{X}_t = -\frac{1}{2}\beta_t dt + \sqrt{\beta_t dt} \varepsilon_t$$

Так как матрица ковариаций  $\varepsilon_t$  не диагональна, оно не может быть приращением винеровского процесса, поэтому это стохастическое дифференциальное уравнение решать будет неудобно. Сведём его к винеровскому процессу. Так как матрица  $C$  положительно определена и диагональна, у неё существует спектральное разложение, такое, что матрица из собственных векторов ортогональна, то есть,  $C = VSV^T$ , где матрица  $S$  диагональна и все её значения неотрицательны в следствие положительной полуопределённости матрицы  $C$ . Значит, у матрицы  $S$  легко берётся корень, и можно ввести матрицу  $V' = V\sqrt{S}$ . Тогда

$$\sqrt{dt}\varepsilon_t = V'\varepsilon'_t \quad \varepsilon'_t \sim \mathcal{N}(\vec{0}; dtI_\tau)$$

Значит, теперь можно переписать наше стох. дифференциальное уравнение через многомерный винеровский процесс:

$$d\tilde{X}_t = -\frac{1}{2}\beta_t dt + \sqrt{\beta_t} V' d\vec{W}_t$$

Тогда можно воспользоваться формулой Фоккера–Планка, и получить последовательно преобразований обратное СДУ и эквивалентное ОДУ.

$$\text{Прямое СДУ: } d\tilde{X}_t = -\frac{1}{2}\beta_t dt + \sqrt{\beta_t} V' d\vec{W}_t$$

$$\text{Обратное СДУ: } d\tilde{X}_t = \beta_t \left( -\frac{1}{2}\tilde{X}_t + C\nabla_x \ln p_t(x) \Big|_{x=\tilde{X}_t} \right) dt + \sqrt{\beta_t} d\vec{W}_t$$

$$\text{Эквивалентное ОДУ: } d\tilde{X}_t = -\frac{1}{2}\beta_t \left( \tilde{X}_t + C\nabla_x \ln p_t(x) \Big|_{x=\tilde{X}_t} \right) dt$$